

# 추진 방향 및 아키텍처 전략

OCP 네이티브 환경에 자연스럽게 녹아드는 AI 통합

## 📍 추진 방향

기존 OpenShift 환경을 보존하면서 OpenShift Lightspeed의 기능을 사내 환경(RAG, Agent, 보안)에 맞게 통합합니다. OpenShift Console의 공식 확장 방식을 준수하여 신규 Plugin과 AI Gateway로 **OCP에 자연스럽게 녹아드는 아키텍처**를 구현합니다.

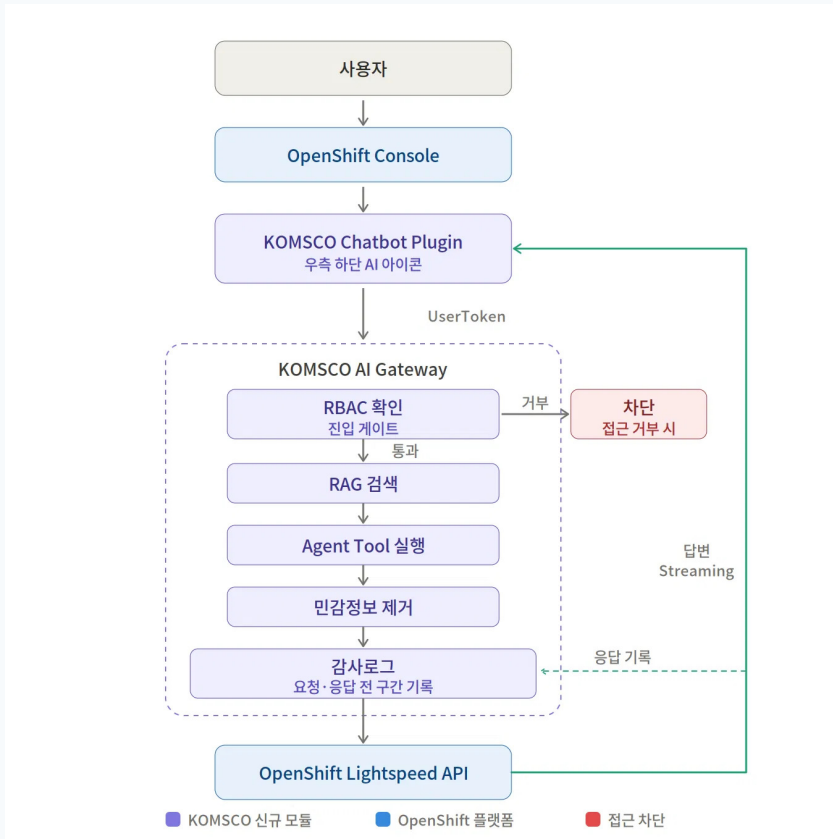
## 🏗️ 핵심 수행 전략

| 구분         | 수행 방안                                          | 기대 효과                   |
|------------|------------------------------------------------|-------------------------|
| 기존 UI 처리   | Console Operator로 기존 Lightspeed plugin 비활성화    | 충돌 방지 및 단일 진입점 확보       |
| API 활용     | Lightspeed REST API(/v1/streaming_query) 연동 유지 | 성능 및 답변 품질 보장           |
| 신규 UI 개발   | Dynamic Console Plugin 기반 자체 UI 개발             | OCP 네이티브 UX 제공 및 확장성 확보 |
| Gateway 구축 | RAG, Agent Tool, 보안/감사를 전담하는 AI Gateway 배치     | 권한 통제(RBAC) 및 보안성 강화    |

✓ AI Gateway를 통해 RAG 연동, 감사로그 적재 및 민감정보 필터링을 수행하여 CORS, 인증, RBAC 측면에서 안정적인 통합을 제공합니다.

# 목표 아키텍처 및 데이터 흐름

## AIOps Agentic Model 기반의 End-to-End 연동 구조



### RBAC 및 진입 통제

OpenShift UserToken 기반 인증. 권한 미달 시 AI Gateway 진입 단계에서 원천 차단.

### KOMSCO AIOps Agentic Model

특화 모델이 질문의 OS Context를 판단하고, Tool Plan JSON을 생성하여 Evidence 기반 RCA Reasoning을 수행합니다.

- ✓ OS Context 판단 (Linux/Windows/OCP)
- ✓ Tool Plan JSON 생성
- ✓ 위험 작업 승인 여부 판단

### OS-aware Tool Adapter


모델이 추상화된 Tool Plan을 내리면, Linux / Windows / OpenShift 환경에 맞는 실제 조회 명령으로 변환하여 안전하게 실행합니다.

### 안전한 Lightspeed 연동

민감정보(Secrets 등)를 제거하고 전 구간 감사로그를 적재한 뒤, Lightspeed API를 통해 최종 RCA 및 조치 가이드를 Streaming 제공합니다.

# Lightspeed + AI Gateway 연동 흐름


AI Ops Model의 Tool Plan을 바탕으로 각자의 전문 영역을 조회하여 최종 답변으로 통합



# AIOps Agentic Model 적용 전략

Lightspeed가 정확한 RCA 답변을 생성할 수 있도록 Tool Plan과 Evidence Context를 구조화

## 모델 적용 위치



## 모델 핵심 역할 정의

| 구성 요소                 | 역할                                              | 예시                                                       |
|-----------------------|-------------------------------------------------|----------------------------------------------------------|
| OS Context Classifier | 대상 환경이 OpenShift, Linux, Windows 중 어디에 해당하는지 판단 | Pod 재시작, Linux 서비스 장애, Windows 이벤트 로그 장애                 |
| Tool Router           | 질문에 필요한 조회 도구를 자동 선택                            | read_tool, find_tool, grep_tool, oc_tool, metric_tool    |
| Evidence Planner      | 어떤 증거를 어떤 순서로 조회할지 계획                           | Event → Log → Metric → Alert → Snapshot                  |
| RCA Reasoner          | 수집된 증거를 분석하여 Lightspeed에 전달할 원인 후보와 Context 정리  | OOMKilled, ImagePullBackOff, DiskPressure, Service Crash |
| JSON Formatter        | Lightspeed가 활용할 수 있는 구조화된 Context JSON 생성       | tool_plan, evidence, root_cause, confidence              |
| Safety Guard          | 위험 명령 차단 및 승인 필요 여부 판단                          | delete, patch, restart, scale 작업은 승인 필요 (차단)             |



KOMSCO AIOps Model은 Lightspeed가 최종 RCA 답변을 생성할 수 있도록 Tool Plan을 수립하고, 사내 Evidence와 OS별 Context를 구조화하여 공급하는 핵심 확장 계층입니다.

# AIOps Agentic Model 라인업 비교

도입 목적에 따른 최적의 AIOps Agentic Model 선정 근거

| 비교 항목        | 🏠 Qwen3.6-27B                                                | ⚡ Gemma 4 26B A4B                                      | 🛠️ AIOps 적용 관점 판단                               |
|--------------|--------------------------------------------------------------|--------------------------------------------------------|-------------------------------------------------|
| 모델 성격        | Agentic Coding, 복합 Reasoning 강조                              | 고효율 추론, Function Calling, 빠른 Triage                    | Qwen: 깊은 Tool Reasoning에 유리<br>Gemma: 속도·비용 효율적 |
| 구조 / 컨텍스트    | 27B 전체 파라미터 활성화 (262K)                                       | MoE 구조 (토큰당 3.8B 활성화, 256K)                            | 장시간 RCA·복잡 체인: Qwen 우세<br>대량 로그 요약: Gemma 우수    |
| Tool Calling | Qwen-Agent 등 Tool Call 파서 강점                                 | Function Calling 및 Tool Token 체계 제공                    | AIOps Tool Plan JSON은 Qwen 기반 추천                |
| OS 진단 지표     | Terminal-Bench, SWE-bench 지표 우수                              | 일반 코딩/추론에 강점                                           | Linux 명령어 기반 추론 등은 Qwen 우선                      |
| 추론 비용/속도     | 품질 우선 (긴 컨텍스트 시 GPU 부담 큼)                                    | 속도 우선 (MoE 특성상 빠름)                                     | 품질 중심은 Qwen, 속도/비용 중심은 Gemma 적합                 |
| 학습(SFT) 용이성  | Dense 계열로 SFT 설계 상대적 단순                                      | MoE: Routing 안정성 고려 필요                                 | AIOps 전문화 출발점으로 Qwen 권장                         |
| 권장 역할        | <b>AIOps Agentic Model</b><br>(OS Tool Plan 생성, RCA JSON 생성) | <b>Fast Assistant Model</b><br>(Alert 1차 분류, 대량 로그 요약) | 도입 환경의 우선순위(정확도 vs 효율성)에 따라 택일                  |



정확한 RCA와 전문 Tool Reasoning이 핵심이라면 **Qwen3.6-27B**를, 빠른 요약·분류와 추론 효율성이 핵심이라면 **Gemma 4 26B A4B**를 선택하는 것이 적합합니다.

본 사업의 요구사항과 인프라 환경을 종합적으로 고려하여 최적의 단일 모델을 선정할 것을 제안합니다.

# OS-aware Tool Reasoning 모델 구조

동일한 장애 질문도 Linux/Windows/OCP 환경에 따라 적절한 Tool과 명령 체계를 선택



## ↔ 대표 Tool 매핑 구조

| 추상 Tool      | 🐧 Linux Adapter             | 🪟 Windows Adapter         | ⚙️ OpenShift Adapter       |
|--------------|-----------------------------|---------------------------|----------------------------|
| read_tool    | cat, tail, journalctl       | Get-Content, Get-WinEvent | oc get, oc describe        |
| find_tool    | find, locate                | Get-ChildItem             | oc get all, label selector |
| grep_tool    | grep, rg, journalctl --grep | Select-String             | log/event pattern search   |
| service_tool | systemctl status            | Get-Service               | oc get co, Operator 상태     |
| process_tool | ps, top, pidstat            | Get-Process               | Pod/container 상태           |
| metric_tool  | node exporter metric        | Get-Counter               | Prometheus/Thanos query    |

**i** 모델은 운영 명령을 직접 실행하지 않고, **read\_tool, find\_tool** 등 추상화된 **Tool Plan**을 **JSON**으로 생성합니다. 실제 실행은 AI Gateway의 Tool Adapter가 담당하며, **OS별 명령 변환, RBAC 검증, 민감정보 제거, 감사로그 기록**을 수행합니다.



# Tool Plan JSON 기반 Lightspeed Context 강화 구조

Lightspeed가 활용할 수 있도록 Tool 계획과 증적 Context를 JSON으로 표준화

## </> Agent Plan JSON (Tool Plan 예시)

```
{
  "task_type": "pod_restart_rca",
  "target": { "platform": "openshift" },
  "execution_policy": { "mode": "read_only" },
  "tool_plan": [
    { "step": 1, "tool": "event_tool" },
    { "step": 2, "tool": "grep_tool" },
    { "step": 3, "tool": "metric_tool" }
  ]
}
```

## 📄 최종 RCA Context JSON 예시

```
{
  "cause_candidates": "Deployment memory limit 감소 -> Pod OOM",
  "confidence": 0.86,
  "evidence": [ { "type": "event" } ],
  "action_candidates": [ "memory limit 복구" ]
}
```

**i** 여기서 말하는 JSON은 Lightspeed가 최종 답변을 생성하기 전에 AI Gateway가 수행할 Tool 계획, 증적 수집 범위, 위험도, 신뢰도를 구조화한 Context입니다.



# Evidence 기반 AI 장애 분석 시나리오

사용자 질문에 대해 AI Gateway가 과거 증거 기반 RCA를 수행하는 흐름



사용자 질문 (Chat UI)

"어제 새벽에 default namespace Pod가 왜 재시작됐어?"

## 1. Agentic Tool Plan 생성

- 1 OS/OCP Context 판단**  
모델이 질문을 분석하여 OpenShift Pod 재시작 RCA  
질의로 분류
- 2 Tool Plan JSON 생성**  
event\_tool, grep\_tool, metric\_tool,  
snapshot\_tool 선택
- 3 Tool Adapter 실행**  
선택된 Tool을 환경에 맞는 명령으로 변환하여 안전하  
게 실행

## 2. Evidence 기반 다각도 분석

- 4 과거 이벤트 조회**  
해당 시간대 Pod Event, Killing, OOMKilled,  
Eviction 등 확인
- 5 과거 로그 분석**  
재시작 전후 Container Log에서 OOM 등 오류 패턴  
추출
- 6 장기 메트릭 분석**  
CPU/Memory 사용량, Node Pressure, Restart 추  
세 확인

## 3. Context 구조화 및 Lightspeed 연동

- 7 RCA Context JSON 생성**  
수집된 증거, 원인 후보, 신뢰도, 조치 후보를 구조화
- 8 Lightspeed 기반 최종 분석**  
RCA Context와 사내 Runbook을 OpenShift  
Lightspeed에 전달하여 최종 답변 생성
- 9 최종 답변 제공**  
RCA, 즉시 조치, 재발 방지책, 참고 증거를 Chat UI에  
제공



본 구축안은 OpenShift Lightspeed의 기본 AI 분석 역량을 유지하면서, KOMSCO AI Gateway가 사내 Runbook/RAG, 과거 Evidence, OS별 Tool Context를 보강하여 보다 정확하고 안전한 AIOps 답변을 제공하는 확장형 아키텍처입니다.

# 단계별 구축 로드맵 및 운영 안정성 확보 방안

Operator/OLM 기반 Software Catalog 표준 배포 체계

## 🗺️ 5단계 구축 로드맵

| 단계  | 수행 작업                      | 상세 내용                                                                                      |
|-----|----------------------------|--------------------------------------------------------------------------------------------|
| 1단계 | 전용 Namespace 및 권한 경계 구성    | komsco-ai Namespace, ServiceAccount, 최소 권한 RBAC, NetworkPolicy, Service CA 기반 TLS 영역 확보    |
| 2단계 | AI Gateway 및 Plugin 이미지 빌드 | AI Gateway, Console Dynamic Plugin, RAG/Tool Adapter 이미지를 사내 Registry에 표준 태그로 배포           |
| 3단계 | Operator/OLM 카탈로그 패키징      | KOMSCO AI Operator를 CRD/CSV/Bundle/CatalogSource로 패키징하여 Software Catalog 설치 항목으로 제공        |
| 4단계 | CR 기반 자동 배포 및 Console 연동   | KomscoAIAssistant CR 생성 시 Operator가 Gateway, Plugin Service, ConsolePlugin CR, RBAC를 자동 구성 |
| 5단계 | UI 전환 및 운영 안정화             | 기존 Lightspeed UI 비활성화, 신규 Plugin 활성화, OLM 업그레이드 채널, 모니터링, 감사로그, 롤백 절차 안정화                  |

## 📋 운영 안정성 확보 체크리스트

| 점검 영역         | 주요 점검 및 수행 항목                                                   |
|---------------|-----------------------------------------------------------------|
| 배포/업그레이드 통제   | OLM Channel, Subscription, InstallPlan 승인 정책, CSV 상태 점검         |
| 카탈로그 관리       | 사내 CatalogSource, Bundle/Image 서명 또는 Digest 고정, 망분리 Registry 반영 |
| Operator 안정성  | CR status condition, reconcile 오류 이벤트, metrics/alert 구성         |
| Console 전환 통제 | 기존 Lightspeed Console Plugin 비활성화와 신규 Plugin 활성화를 CR 옵션으로 명시    |
| 롤백 전략         | 이전 Operator channel 또는 이전 Bundle로 복구, ConsolePlugin 원복 절차 확보    |

✔️ Dynamic Console Plugin과 AI Gateway를 KOMSCO AI Operator로 제품화하고 Software Catalog에서 설치·업그레이드하는 방식이 OpenShift 표준 운영 모델에 가장 부합하는 안정적인 구축 방안입니다.

# GB10 2노드 모델 구성안 3종

엔지니어 검토용 요약 · 한국어 적합성, 운영성, 토큰 생성속도를 기준으로 3개 구성안을 비교

비교 기준: 한국어 품질 | 복합 RCA 품질 | 동시성 / 처리량 | 운영 복잡도 | 향후 확장성

### 1안 혼합형

모델 및 노드 배치

Mistral Small 4 119B (6.5B active/token); Gemma 4 26B A4B — GB10 #1: Mistral / #2: Gemma

예상 출력 속도

Mistral 23-30 tok/s · Gemma 24-40 tok/s (단일 요청 기준)

+ 주요 장점

- 깊은 RCA와 빠른 일반 질의를 분리 운영
- 한국어·멀티모달·RAG·Tool Calling 균형 우수
- 업무 성격별 라우팅으로 응답속도 개선

- 주의 / 한계

- 모델 이원화로 운영·모니터링 복잡도 증가
- 한 노드 장애 시 담당 기능·응답 품질 저하 (비대칭 Failover)

### 2안 Active-Active 이중화형

모델 및 노드 배치

Gemma 4 26B A4B Replica ×2 — 양쪽 동일 구성

예상 출력 속도

노드당 24-40 tok/s; 독립 요청 2건 합산 48-80 tok/s

+ 주요 장점

- 동일 모델 2노드 Active-Active로 단순·안정적
- 동시성·처리량·장애 대응에서 우수
- 운영 질의, 요약, 검색형 응답에 적합

- 주의 / 한계

- 복합 RCA·긴 보고서 품질은 1안 대비 열세
- 심층 추론 작업은 별도 승격 경로 필요

### 3안 대형모델 결합형

모델 및 노드 배치

GB10 #1 + #2 분산 추론 결합 (TP/EP) — 제조사 공개 기준 최대 405B급 구동 범위

검증 요구사항

출력 성능: 모델·정밀도·분산 방식에 따라 상이, PoC 실측

+ 주요 장점

- 대형모델 구동은 기술 검증·시연 가치 존재
- 벤치마크·최대 모델 규모 검증 활용 가능

- 주의 / 한계

- 한국어 품질 리스크·노드 간 통신 병목
- 동시성 낮고 운영 난이도 높아 주력 서비스 부적합

\* tok/s는 출력 Decode 기준 예상값이며, TTFT·컨텍스트 길이·양자화 방식·추론 엔진·동시성에 따라 달라지므로 PoC에서 확정합니다.

# 구성안 상세 비교표

배치 구조, 예상 성능, 운영 특성을 표로 비교

| 항목              | 1안 혼합형                                                                 | 2안 Gemma Active-Active                  | 3안 대형모델 결합                                          |
|-----------------|------------------------------------------------------------------------|-----------------------------------------|-----------------------------------------------------|
| 노드 배치           | GB10 #1 Mistral / GB10 #2 Gemma                                        | GB10 #1 Gemma / GB10 #2 Gemma           | GB10 #1 + #2 분산 추론 결합(TP/EP, 모델별 적용)                |
| 주요 모델           | Mistral Small 4 119B / Gemma 4 26B A4B                                 | Gemma 4 26B A4B × 2                     | 후보 예시: Llama 4 Maverick 400B, Nemotron Ultra 253B 등 |
| 단일 요청 출력 속도     | Mistral 23~30 tok/s / Gemma 24~40 tok/s                                | 노드당 24~40 tok/s                         | 참고 범위 8~20 tok/s(비보장, PoC 실측)                       |
| 서비스 합산 처리량      | 두 노드 동시 가동 기준, 독립 요청 2건 이론 합산 약 47~70 tok/s<br>(실제 처리량은 라우팅 비율에 따라 변동) | 독립 요청 2건 합산 48~80 tok/s                 | 모델 수용량 확대 목적의 분산 추론으로, 동시 처리량 증가는 제한적               |
| 한국어 적합성 사전 기대치  | 높음                                                                     | 중상                                      | 낮음 ~ 불확실                                            |
| 복합 RCA 품질       | 상                                                                      | 중                                       | 중 ~ 상, 모델 의존                                        |
| 운영 복잡도(낮을수록 유리) | 중                                                                      | 하                                       | 상                                                   |
| 장애 대응성          | 기능 저하형 Failover (한 노드 장애 시 서비스 유지, 품질 저하)                              | 동일 모델 Active-Active (무중단 우회 및 용량 축소 운영) | 하, 결합 구성 의존                                         |
| 적합한 용도          | 주력 운영형                                                                 | 고처리량·HA형                                | 비추천 / 검증형                                           |

1안은 모델 특성별 역할 분리로 품질과 속도 균형이 우수

2안은 동일 모델 2노드로 운영·HA 설계가 단순

3안은 한국어 품질·동시성·운영성에서 주력 서비스 부적합

\* tok/s는 출력 Decode 기준 예상값이며, 성능 수치와 정성 등급은 사전 아키텍처 가설입니다. 양자화 방식·추론 엔진·입출력 길이·동시성에 따라 달라지므로 PoC에서 확정합니다.

# 선정 판단표 및 적용 권장

점수는 PoC 이전 아키텍처 가설에 따른 상대평가이며, 최종 점수는 실측 결과로 확정합니다. (별점이 높을수록 유리)

| 평가 항목         | 1안 혼합형 | 2안 Gemma Active-Active | 3안 대형모델 결합 |
|---------------|--------|------------------------|------------|
| 한국어 품질        | ★★★★★  | ★★★★★                  | ★★★★★      |
| 단일 요청 출력 속도   | ★★★★★  | ★★★★★                  | ★★★★★      |
| 복합 RCA 품질     | ★★★★★  | ★★★★★                  | ★★★★★      |
| 서비스 처리량 / 동시성 | ★★★★★  | ★★★★★                  | ★★★★★      |
| 운영 단순성        | ★★★★★  | ★★★★★                  | ★★★★★      |
| 확장성 / HA      | ★★★★★  | ★★★★★                  | ★★★★★      |
| 실운영 적합도       | ★★★★★  | ★★★★★                  | ★★★★★      |

## 1안 적용 권장

- 1안을 기본 운영안으로 적용
- 심층 RCA, 보고서, 일반 질의를 역할 분리
- 초기 PoC는 라우팅 / 승격 정책 검증 중심으로 진행

## 2안 병행 검토

- 2안은 고처리량·HA 대안으로 병행 검토
- 처리량·HA·운영 단순성이 중요한 경우 적합
- 복합 RCA는 내부 상위 추론 모델로의 승격 경로 검토 가능

## 3안 제한 적용

- 3안은 주력 서비스용이 아니라 한계 검증용
- 한국어 품질·동시성 리스크 큼 (품질은 모델별 별도 검증)
- 기술 시연 또는 벤치마크 용도로만 제한 권고

**PoC 체크포인트:** 한국어 운영질의 정확도, RCA 증적 일치율, TTFT p50/p95, 단일 요청 출력 속도(Decode tok/s), 동시성 1/4/8 처리량, JSON Schema 유효율, Tool Call 정확도, Failover RTO,가중치·KV Cache 포함 메모리 여유율

# 소규모 RAG Vector 저장소 비교 및 권장 배치안

Dell Pro Max GB10 단일 장비 환경에 최적화된 자원 효율적 DB 선정 및 구성 방안

| 비교 항목                           | PostgreSQL + pgvector      | Qdrant                    | OpenSearch                          | Milvus                     |
|---------------------------------|----------------------------|---------------------------|-------------------------------------|----------------------------|
| 동일 장비 배치 적합성                    | 매우 높음                      | 높음                        | 낮음~중간                               | 낮음                         |
| 자원 사용량                          | 낮음                         | 낮음~중간                     | 중간~높음                               | 높음                         |
| 검색 방식                           | Exact(Flat), HNSW, IVFFlat | HNSW, Dense-Sparse Hybrid | BM25 + Vector Hybrid                | HNSW, IVF, DiskANN, Hybrid |
| 메타데이터·권한 필터                     | SQL, JOIN, WHERE, RLS      | Payload Filter            | Query Filter + Index/Doc/Field RBAC | Scalar Filter              |
| 백업·복구                           | PostgreSQL 표준 체계           | Snapshot                  | Snapshot                            | 분산 백업 구성                   |
| 운영 난이도                          | 낮음                         | 중간                        | 중간~높음                               | 높음                         |
| 보안·감사 요건 대응<br>용이성 (사전 아키텍처 평가) | 높음                         | 중상                        | 기존 운영 시 높음                          | 현 규모에는 과도                  |
| 본 사업 판단                         | 기본안                        | 성능 중심 대안                  | 기존 구축 시만 검토                         | 제외 권고                      |

## 단일 장비 권장 배치 구조

Dell Pro Max GB10

- LLM Inference Server
- AI Gateway (DB 접근 통제)
- Embedding / Reranker
- PostgreSQL + pgvector
  - Document Metadata / Chunk Text
  - Embedding Vector / ACL Metadata

## 권장 시작 자원 및 정책

|           |                                           |
|-----------|-------------------------------------------|
| DB 구성     | PostgreSQL + pgvector 단일 Primary          |
| CPU / 메모리 | Req 2 vCPU/4GiB, Limit 4 vCPU/8GiB        |
| 로컬 저장공간   | NVMe 100GB (PGDATA·WAL·Index)             |
| 외부 NAS    | 원본 문서·Base Backup·WAL Archive             |
| 검색 방식     | Exact 우선, p95 초과 시 HNSW                   |
| 접근 정책     | Gateway 전용 계정, 외부 직접접속 차단, 최소권한·TLS       |
| 백업·복구     | PoC: Dump / 운영: Base Backup + WAL Archive |

[I/O 경로 분리] 로컬 NVMe에는 운영 DB(데이터·WAL·Index)를 배치하고, 외부 NAS는 원본 문서 및 백업 저장소로 분리하여 NAS 장애가 온라인 검색에 영향을 주지 않도록 구성한다.

\* 오픈소스 라이선스: PostgreSQL + pgvector — PostgreSQL License / Qdrant·OpenSearch·Milvus — Apache 2.0

**[결론]** Dell Pro Max GB10에 LLM과 함께 배치하는 소규모 RAG 환경에서는 **PostgreSQL + pgvector**를 기본안으로 적용한다. Qdrant는 전용 벡터 검색 성능이 필요한 경우 대안으로 검토하고, OpenSearch는 기존 운영 클러스터를 재사용할 수 있는 경우에만 검토한다.