

추진 방향 및 아키텍처 전략

OCP 네이티브 환경에 자연스럽게 녹아드는 AI 통합

📍 추진 방향

기존 OpenShift 환경을 보존하면서 OpenShift Lightspeed의 기능을 사내 환경(RAG, Agent, 보안)에 맞게 통합합니다. OpenShift Console의 공식 확장 방식을 준수하여 신규 Plugin과 AI Gateway로 **OCP에 자연스럽게 녹아드는 아키텍처**를 구현합니다.

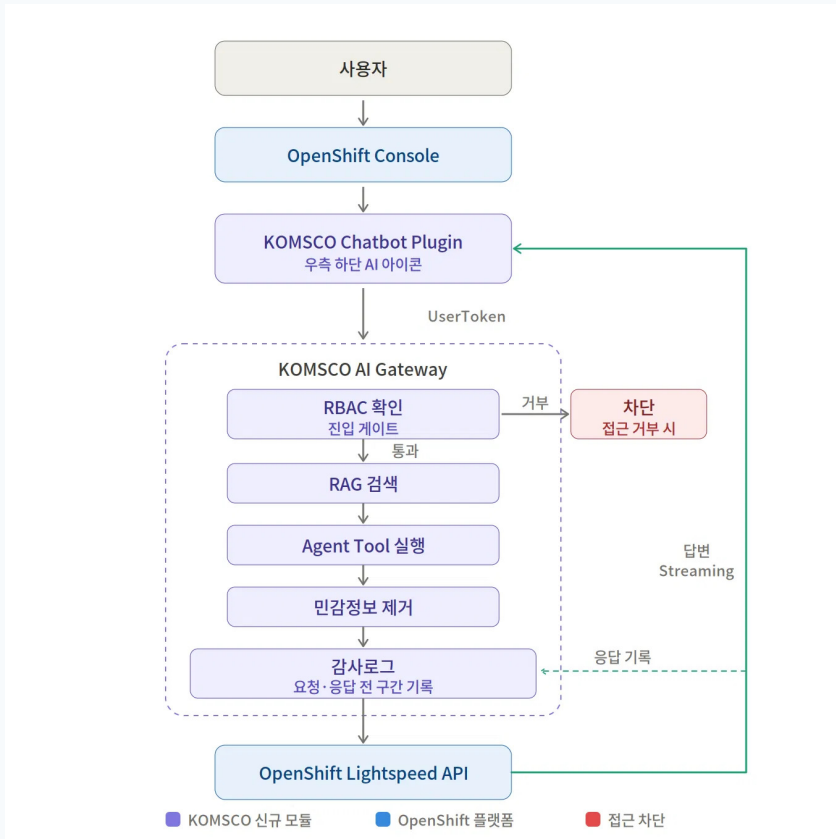
🏗️ 핵심 수행 전략

구분	수행 방안	기대 효과
기존 UI 처리	Console Operator로 기존 Lightspeed plugin 비활성화	충돌 방지 및 단일 진입점 확보
API 활용	Lightspeed REST API(/v1/streaming_query) 연동 유지	성능 및 답변 품질 보장
신규 UI 개발	Dynamic Console Plugin 기반 자체 UI 개발	OCP 네이티브 UX 제공 및 확장성 확보
Gateway 구축	RAG, Agent Tool, 보안/감사를 전담하는 AI Gateway 배치	권한 통제(RBAC) 및 보안성 강화

✓ AI Gateway를 통해 RAG 연동, 감사로그 적재 및 민감정보 필터링을 수행하여 CORS, 인증, RBAC 측면에서 안정적인 통합을 제공합니다.

목표 아키텍처 및 데이터 흐름

AIOps Agentic Model 기반의 End-to-End 연동 구조



RBAC 및 진입 통제

OpenShift UserToken 기반 인증. 권한 미달 시 AI Gateway 진입 단계에서 원천 차단.

KOMSCO AIOps Agentic Model

특화 모델이 질문의 OS Context를 판단하고, Tool Plan JSON을 생성하여 Evidence 기반 RCA Reasoning을 수행합니다.

- ✓ OS Context 판단 (Linux/Windows/OCP)
- ✓ Tool Plan JSON 생성
- ✓ 위험 작업 승인 여부 판단

OS-aware Tool Adapter


모델이 추상화된 Tool Plan을 내리면, Linux / Windows / OpenShift 환경에 맞는 실제 조회 명령으로 변환하여 안전하게 실행합니다.

안전한 Lightspeed 연동

민감정보(Secrets 등)를 제거하고 전 구간 감사로그를 적재한 뒤, Lightspeed API를 통해 최종 RCA 및 조치 가이드를 Streaming 제공합니다.

Lightspeed + AI Gateway 연동 흐름


AI Ops Model의 Tool Plan을 바탕으로 각자의 전문 영역을 조회하여 최종 답변으로 통합



AIOps Agentic Model 적용 전략

Lightspeed가 정확한 RCA 답변을 생성할 수 있도록 Tool Plan과 Evidence Context를 구조화

모델 적용 위치



모델 핵심 역할 정의

구성 요소	역할	예시
OS Context Classifier	대상 환경이 OpenShift, Linux, Windows 중 어디에 해당하는지 판단	Pod 재시작, Linux 서비스 장애, Windows 이벤트 로그 장애
Tool Router	질문에 필요한 조회 도구를 자동 선택	read_tool, find_tool, grep_tool, oc_tool, metric_tool
Evidence Planner	어떤 증거를 어떤 순서로 조회할지 계획	Event → Log → Metric → Alert → Snapshot
RCA Reasoner	수집된 증거를 분석하여 Lightspeed에 전달할 원인 후보와 Context 정리	OOMKilled, ImagePullBackOff, DiskPressure, Service Crash
JSON Formatter	Lightspeed가 활용할 수 있는 구조화된 Context JSON 생성	tool_plan, evidence, root_cause, confidence
Safety Guard	위험 명령 차단 및 승인 필요 여부 판단	delete, patch, restart, scale 작업은 승인 필요 (차단)



KOMSCO AIOps Model은 Lightspeed가 최종 RCA 답변을 생성할 수 있도록 Tool Plan을 수립하고, 사내 Evidence와 OS별 Context를 구조화하여 공급하는 핵심 확장 계층입니다.

AIOps Agentic Model 라인업 비교

도입 목적에 따른 최적의 AIOps Agentic Model 선정 근거

비교 항목	🏠 Qwen3.6-27B	⚡ Gemma 4 26B A4B	🛠️ AIOps 적용 관점 판단
모델 성격	Agentic Coding, 복합 Reasoning 강조	고효율 추론, Function Calling, 빠른 Triage	Qwen: 깊은 Tool Reasoning에 유리 Gemma: 속도·비용 효율적
구조 / 컨텍스트	27B 전체 파라미터 활성화 (262K)	MoE 구조 (토큰당 3.8B 활성화, 256K)	장시간 RCA·복잡 체인: Qwen 우세 대량 로그 요약: Gemma 우수
Tool Calling	Qwen-Agent 등 Tool Call 파서 강점	Function Calling 및 Tool Token 체계 제공	AIOps Tool Plan JSON은 Qwen 기반 추천
OS 진단 지표	Terminal-Bench, SWE-bench 지표 우수	일반 코딩/추론에 강점	Linux 명령어 기반 추론 등은 Qwen 우선
추론 비용/속도	품질 우선 (긴 컨텍스트 시 GPU 부담 큼)	속도 우선 (MoE 특성상 빠름)	품질 중심은 Qwen, 속도/비용 중심은 Gemma 적합
학습(SFT) 용이성	Dense 계열로 SFT 설계 상대적 단순	MoE: Routing 안정성 고려 필요	AIOps 전문화 출발점으로 Qwen 권장
권장 역할	AIOps Agentic Model (OS Tool Plan 생성, RCA JSON 생성)	Fast Assistant Model (Alert 1차 분류, 대량 로그 요약)	도입 환경의 우선순위(정확도 vs 효율성)에 따라 택일



정확한 RCA와 전문 Tool Reasoning이 핵심이라면 **Qwen3.6-27B**를, 빠른 요약·분류와 추론 효율성이 핵심이라면 **Gemma 4 26B A4B**를 선택하는 것이 적합합니다.

본 사업의 요구사항과 인프라 환경을 종합적으로 고려하여 최적의 단일 모델을 선정할 것을 제안합니다.

OS-aware Tool Reasoning 모델 구조

동일한 장애 질문도 Linux/Windows/OCP 환경에 따라 적절한 Tool과 명령 체계를 선택



↔ 대표 Tool 매핑 구조

추상 Tool	🐧 Linux Adapter	🪟 Windows Adapter	⚙️ OpenShift Adapter
read_tool	cat, tail, journalctl	Get-Content, Get-WinEvent	oc get, oc describe
find_tool	find, locate	Get-ChildItem	oc get all, label selector
grep_tool	grep, rg, journalctl --grep	Select-String	log/event pattern search
service_tool	systemctl status	Get-Service	oc get co, Operator 상태
process_tool	ps, top, pidstat	Get-Process	Pod/container 상태
metric_tool	node exporter metric	Get-Counter	Prometheus/Thanos query

i 모델은 운영 명령을 직접 실행하지 않고, **read_tool, find_tool** 등 추상화된 **Tool Plan**을 **JSON**으로 생성합니다. 실제 실행은 AI Gateway의 Tool Adapter가 담당하며, **OS별 명령 변환, RBAC 검증, 민감정보 제거, 감사로그 기록**을 수행합니다.

Tool Plan JSON 기반 Lightspeed Context 강화 구조

Lightspeed가 활용할 수 있도록 Tool 계획과 증적 Context를 JSON으로 표준화

</> Agent Plan JSON (Tool Plan 예시)

```
{
  "task_type": "pod_restart_rca",
  "target": { "platform": "openshift" },
  "execution_policy": { "mode": "read_only" },
  "tool_plan": [
    { "step": 1, "tool": "event_tool" },
    { "step": 2, "tool": "grep_tool" },
    { "step": 3, "tool": "metric_tool" }
  ]
}
```

📄 최종 RCA Context JSON 예시

```
{
  "cause_candidates": "Deployment memory limit 감소 -> Pod OOM",
  "confidence": 0.86,
  "evidence": [ { "type": "event" } ],
  "action_candidates": [ "memory limit 복구" ]
}
```

i 여기서 말하는 JSON은 Lightspeed가 최종 답변을 생성하기 전에 AI Gateway가 수행할 Tool 계획, 증적 수집 범위, 위험도, 신뢰도를 구조화한 Context입니다.

Evidence 기반 AI 장애 분석 시나리오

사용자 질문에 대해 AI Gateway가 과거 증거 기반 RCA를 수행하는 흐름



사용자 질문 (Chat UI)

"어제 새벽에 default namespace Pod가 왜 재시작됐어?"

1. Agentic Tool Plan 생성

- OS/OCP Context 판단**
모델이 질문을 분석하여 OpenShift Pod 재시작 RCA 질의로 분류
- Tool Plan JSON 생성**
event_tool, grep_tool, metric_tool, snapshot_tool 선택
- Tool Adapter 실행**
선택된 Tool을 환경에 맞는 명령으로 변환하여 안전하게 실행

2. Evidence 기반 다각도 분석

- 과거 이벤트 조회**
해당 시간대 Pod Event, Killing, OOMKilled, Eviction 등 확인
- 과거 로그 분석**
재시작 전후 Container Log에서 OOM 등 오류 패턴 추출
- 장기 메트릭 분석**
CPU/Memory 사용량, Node Pressure, Restart 추세 확인

3. Context 구조화 및 Lightspeed 연동

- RCA Context JSON 생성**
수집된 증거, 원인 후보, 신뢰도, 조치 후보를 구조화
- Lightspeed 기반 최종 분석**
RCA Context와 사내 Runbook을 OpenShift Lightspeed에 전달하여 최종 답변 생성
- 최종 답변 제공**
RCA, 즉시 조치, 재발 방지책, 참고 증거를 Chat UI에 제공



본 구축안은 OpenShift Lightspeed의 기본 AI 분석 역량을 유지하면서, KOMSCO AI Gateway가 사내 Runbook/RAG, 과거 Evidence, OS별 Tool Context를 보강하여 보다 정확하고 안전한 AIOps 답변을 제공하는 확장형 아키텍처입니다.

단계별 구축 로드맵 및 운영 안정성 확보 방안

Operator/OLM 기반 Software Catalog 표준 배포 체계

🗺️ 5단계 구축 로드맵

단계	수행 작업	상세 내용
1단계	전용 Namespace 및 권한 경계 구성	komsco-ai Namespace, ServiceAccount, 최소 권한 RBAC, NetworkPolicy, Service CA 기반 TLS 영역 확보
2단계	AI Gateway 및 Plugin 이미지 빌드	AI Gateway, Console Dynamic Plugin, RAG/Tool Adapter 이미지를 사내 Registry에 표준 태그로 배포
3단계	Operator/OLM 카탈로그 패키징	KOMSCO AI Operator를 CRD/CSV/Bundle/CatalogSource로 패키징하여 Software Catalog 설치 항목으로 제공
4단계	CR 기반 자동 배포 및 Console 연동	KomscoAIAssistant CR 생성 시 Operator가 Gateway, Plugin Service, ConsolePlugin CR, RBAC를 자동 구성
5단계	UI 전환 및 운영 안정화	기존 Lightspeed UI 비활성화, 신규 Plugin 활성화, OLM 업그레이드 채널, 모니터링, 감사로그, 롤백 절차 안정화

📋 운영 안정성 확보 체크리스트

점검 영역	주요 점검 및 수행 항목
배포/업그레이드 통제	OLM Channel, Subscription, InstallPlan 승인 정책, CSV 상태 점검
카탈로그 관리	사내 CatalogSource, Bundle/Image 서명 또는 Digest 고정, 망분리 Registry 반영
Operator 안정성	CR status condition, reconcile 오류 이벤트, metrics/alert 구성
Console 전환 통제	기존 Lightspeed Console Plugin 비활성화와 신규 Plugin 활성화를 CR 옵션으로 명시
롤백 전략	이전 Operator channel 또는 이전 Bundle로 복구, ConsolePlugin 원복 절차 확보

✔️ Dynamic Console Plugin과 AI Gateway를 KOMSCO AI Operator로 제품화하고 Software Catalog에서 설치·업그레이드하는 방식이 OpenShift 표준 운영 모델에 가장 부합하는 안정적인 구축 방안입니다.